

受講者用ハンズオンワークブック：根拠に基づくRAGとガードレール

日本語・受講者用ハンズオンワークブック

著者 [Author]

Rajkumar Rajagobalan

実行可能なColabノートブックと併せて使用してください。冒頭のリンクから開けます。観察結果は紙面または保存したノートブックに記録してください。

氏名またはペアID： _____ 実施日： _____

[日本語版ワークブックをColabで開く](#)

本書は、実行可能なColabノートブック [notebook] と併せて使う演習教材です。まず考え方を理解し、結果を予想してから実行し、観察した事実をもとに結果を説明してください。実装コードは用意してあります。授業では、環境構築用のコードを入力することよりも、システムの動作を確かめることに時間を使います。

作成するのは、**架空の大学図書館**の利用規程に回答するアシスタントです。10件の規程は、この演習のために作成した架空のデータです。貸出延長に関する現行規程と、それに矛盾する旧版の規程を含めています。回答に使う資料の選び方が、結果をどう左右するかを確認しましょう。

英語のコードとの対応： 技術用語には英語を角括弧で併記します。コード、変数名、ファイル名、モデルに送る質問文は英語版と共通です。質問文や規程本文を日本語に置き換えると、翻訳だけでなく検索条件も変わります。授業中は指定された英語の入力を使い、考察は日本語で記入してください。

到達目標

演習終了時には、次のことを説明・実施できるようになることを目指します。

- テキストの分割位置と重なりが、検索器 [retriever] に渡せる根拠資料 [evidence] に与える影響を説明する。
- 検索順位と出典文書を確認し、語彙検索 [lexical retrieval] とベクトル検索 [dense retrieval] を比較する。
- 出典を追跡できる回答を生成し、出典情報の検証 [provenance checking] と、主張が資料に裏付けられているかの確認を区別する。
- 入力制限、架空の引用、資料では答えられない質問、プロンプトインジェクション [prompt injection] をテストする。
- 検索評価指標 [retrieval metrics] を計算し、回答生成を別に評価したうえで、次に実施すべきテストを提案する。

進行と記録する内容

開始からの時間	内容	保存する記録
00–10分	準備と基本概念	事前動作確認の結果
10–30分	Lab 1：チャンク分割とメタデータ	2種類の分割設定の比較
30–55分	Lab 2：検索と絞り込み	検索順位とフィルターの比較
55–60分	休憩・保存	保存済みノートブック
60–85分	Lab 3：根拠に基づく回答とガードレール	回答、引用、拒否テストの結果

開始からの時間	内容	保存する記録
85–110分	Lab 4：評価と攻撃を想定したテスト	評価指標と攻撃テストの考察
110–120分	提出・振り返り	ノートブックとJSONレポート

記録の残し方

本書の表を記録用シートとして使ってください。Colabでは、該当するテキストセル [text cell] を編集するか、実験の直下に **Text** セルを追加して観察結果を書き込みます。各演習の最後には、コードセル [code cell] 内の `reflections['labN']` にも考察を記入します。この文字列がJSON形式の提出レポートに出力されます。

例えば、空の考察欄を次のように置き換えます。

```
reflections['lab1'] = "My two counts were ... . The repeated phrase was ... . This matters because ... ."
```

例文をそのまま提出せず、実測値と自分の解釈を書いてください。引用符の中は日本語で構いません。編集後はそのセルを実行し、実行環境 [runtime] に値を反映します。' ' のままのセルを再実行すると、考察は空に戻ります。また、Colabでは再実行すると前回の出力が置き換わるため、比較に必要な結果は先に記録してください。

準備と基本概念

時間：00–10分。講師が処理の流れ [pipeline] を説明している間に、準備を進めてください。

基本概念：RAGは何を補うのか

検索拡張生成 [Retrieval-Augmented Generation, RAG] は、質問を受け取ったときに関連する資料を検索し、その本文を生成モデル [generative model] に渡す仕組みです。資料群であるコーパス [corpus] には、非公開情報、最近更新された情報、業務固有の情報などを含められます。ただし、資料を渡しただけで正しい回答が保証されるわけではありません。モデルが根拠を正しく読み取る必要があります。

このノートブックには、次の2つの処理があります。

処理	実施すること	主なオブジェクト
事前準備	データの読み込み、本文の分割、埋め込みの作成、インデックス [index] の構築	<code>DOCUMENTS</code> , <code>chunks</code> , <code>dense_matrix</code>
質問への回答	根拠資料の順位付け、利用条件の適用、リクエスト作成、回答生成、出力検証	<code>search</code> , <code>answer_question</code> , <code>generate_grounded</code> , <code>validate_output</code>

検索では、必要な資料を選べずに失敗することがあります。一方、正しい資料を取得できても、回答生成に失敗することがあります。演習では、この2種類の失敗を分けて考えてください。

Step 0.1 : ノートブックを開いて保存する

1. 冒頭のColabリンクを開き、Googleアカウントでログインします。
2. **Copy to Drive** を選び、自分用のコピーを作成します。
3. 名前を `RAG_Workbook_<your-name-or-pair-id>` に変更します。
4. 実行環境の設定で **Python 3** を選び、ハードウェアアクセラレータ [hardware accelerator] は **None / CPU** にします。
5. 目次から、準備A [Setup A]、準備B [Setup B]、Lab 1~4の位置を確認します。

確認：自分で編集できるコピーがあり、4つの演習に移動できますか。

Step 0.2 : OpenAIのAPIキーを設定する

1. Colabの **Secrets** パネルを開きます。
2. `OPENAI_API_KEY` という名前でシークレット [secret] を追加します。大文字・小文字も含めて正確に入力してください。
3. API利用料金を支払える状態のOpenAI APIキーを登録し、このノートブックからのアクセスを有効にします。
4. **準備A：パッケージとシークレット [Setup A]** のコードセルを実行します。

APIキーはリクエストの認証ヘッダー [authorization header] に使われます。モデルに渡すプロンプト [prompt] の一部ではありません。ノートブックの本文、コード、スクリーンショット、提出物には含めないでください。

Step 0.3 : 2種類のAPIが使えることを確認する

1. **準備B：APIクライアントと埋め込みキャッシュ [Setup B]** を読みます。
2. そのコードセルを1回実行します。
3. **READY** が表示されることを確認します。この処理では、埋め込み [embedding] と回答生成の両方のエンドポイント [endpoint] を確認します。
4. `api_calls` は送信を試みたリクエスト数、`usage_log` は成功したリクエストの使用量を記録することを確認します。埋め込みキャッシュ [embedding cache] のキーは、モデルIDと完全一致する入力テキストの組です。

考え方： 事前動作確認 [preflight] を行くと、後の演習に進む前に、アカウントやモデルへのアクセスの問題を発見できます。キャッシュ [cache] は、同じ実行環境内で変更のないテキストを再び埋め込みAPIに送ることを避けます。授業用の40リクエスト制限は、アカウントの課金上限ではありません。準備セルを再実行すると、カウンターとキャッシュはリセットされます。

進めない場合： 401ではシークレット、403・404ではプロジェクトとモデルの利用権限、429では利用枠 [quota] を確認します。2回試しても準備が完了しない場合は、講師に相談し、動作している受講者とペアを組んでください。講師の記録済み出力を、自分が実行した結果として記載しないでください。

準備の記録： READYを確認：_____ 実行環境：_____ ペアID：_____

Lab 1：根拠資料とチャンクの境界

時間：10-30分・対応する章：第1~2章

課題： 出典情報 [provenance] を保持したまま文書を分割し、チャンクの重なり [overlap] が何を変えるかを調べます。コードの確認に3分、実験に12分、記録と話し合いに5分を使います。

実装前に押さえる概念

概念	この演習での意味	重要な理由
文書 [document]	図書館規程の1件分の完全なデータ	元の出典を特定するため
チャンク [chunk]	文書の一部を切り出したテキスト範囲	どの根拠をまとめて検索できるかが決まるため
オーバーラップ [overlap]	隣接する範囲で重複させる単語	境界をまたぐ根拠を残せる一方、重複も生じるため
メタデータ [metadata]	doc_id, title, status	出典確認や検索対象の選別に使うため
チャンクID [chunk ID]	出典IDと開始単語位置の組	取得した箇所を特定するため

このチャンク分割 [chunking] は空白を区切りにしています。サイズの単位は**単語数であり、モデルのトークン数 [token count] ではありません**。文の途中で切れたり、規則と例外が別のチャンクに分かれたりします。その制約を実際に確認します。

Step 1.1：元のデータを確認する

1. DOCUMENTS = [...] で始まるセルを実行します。
2. 10件のデータが表示されることを確認します。
3. D02とD03を探し、本文と状態 [status] を読みます。
4. 現行の貸出延長規程と旧版の規程を区別します。旧版が生成モデルに渡された場合、何が起こり得るかを予想してください。

記入： 現行の出典ID：_____ 旧版の出典ID：_____ 異なる延長日数：_____

Step 1.2：分割関数の処理を追う

chunk_documents を読み、実行前に次の処理をペアの相手に説明します。

- size - overlap は、次の範囲の開始位置まで進む幅 [stride] を決めます。
- words[start:start + size] は、今回切り出す範囲を指定します。
- {**doc, ...} は、元のメタデータを各チャンクへコピーします。
- 最後の break は、文書の末尾まで到達した時点で処理を止めます。

予想： サイズが20、オーバーラップが5の場合、次の範囲は現在の開始位置から _____ 単語先に始まります。

Step 1.3：重なりなしで実行する

1. chunk_documents を含むセルで、CHUNK_SIZE = 20、OVERLAP = 0 に設定します。

2. そのセルを実行します。
3. `Trial chunks` の数値を記録し、表示されたD02の全チャンクを読みます。
4. 境界で途切れた文の一部に印を付けるか、その断片を記録します。1つのチャンクに、延長日数と予約に関する例外の全文が含まれているかを確認してください。

Step 1.4：変更する条件を1つに絞る

1. `CHUNK_SIZE = 20` は維持し、`OVERLAP` だけを 5 に変更します。
2. 同じセルを再実行します。
3. 新しいチャンク数と、重複した語句を1つ記録します。
4. 必要な根拠が同じチャンクに含まれるようになったかを比較します。規程全体がまだ分かれているなら、その結果を記録してください。重なりを増やせば必ず解決するとは限りません。

設定	総チャンク数	境界で切れた箇所・重複した語句	規則と例外が同じチャンクにあるか
20単語・重なり0	_____	_____	_____
20単語・重なり5	_____	_____	_____

Step 1.5：考察を保存し、共通の検索用データを作る

1. `reflections['lab1']` に、2つのチャンク数、境界での観察を示す引用、自分の解釈を書きます。
2. その考察セルを実行します。同時に、**40単語・重なり8**で共通の `chunks` が作られます。
3. Lab 2～4では、この共通設定を使います。実験用の `trial` と、検索の比較基準 `[baseline]` は別のデータです。

確認ポイント [checkpoint]：各チャンクに出典IDと状態があり、設定した単語数を超えていないこと。さらに、考察で実際の分割箇所を示していることを確認してください。

理解を確かめる問い：重なりを増やすと、根拠を拾いやすくなる一方で、なぜインデックス作成のコストや検索結果の重複が増えるのでしょうか。

回答： _____

Lab 2：検索と根拠資料の絞り込み

時間：30–55分・対応する章：第2～3章

課題：2つの検索方式を比較し、現行規程への回答に旧版の資料が使われないようにします。コードの確認に4分、実験に16分、記録と話し合いに5分を使います。

実装前に押さえる概念

語彙検索 [lexical retrieval] は、語の一致を手掛かりにします。TF-IDFは、チャンク内とコーパス全体での語の出現状況に応じて重みを付けます。用語が一致する質問には有効ですが、異なる語で言い換えた質問 `[paraphrase]` を取りこぼすことがあります。

ベクトル検索 [dense retrieval] は、埋め込みベクトル [embedding vector] を比較します。このノートブックでは、チャンクと質問に同じ埋め込みモデルを使い、ベクトルを正規化 [normalization] してから内積 [dot product] を計算します。長さを1にそろえたベクトルの内積は、コサイン類似度 [cosine similarity] と一致します。これは順位付けのための値であり、資料や回答が正しい確率ではありません。

利用条件による絞り込み [eligibility filtering] は、アプリケーションがどの資料を検索対象にできるかを決めます。この演習では `status == 'current'` が条件です。現行規程かどうかを扱う条件であり、利用者のアクセス権限 [authorization] を管理したり、規程の内容が正しいと証明したりするものではありません。

上位k件 [top-k] は、ここでは出典文書を重複なくk件選ぶという意味です。各出典から最もスコアの高いチャンクを選び、同じ `doc_id` の別チャンクは飛ばします。生成モデルに渡すのは選ばれた箇所だけで、文書全体ではありません。

Step 2.1：インデックスを構築して確認する

1. Lab 2の `tfidf = TfidfVectorizer(...)` で始まるセルを実行します。
2. 表示された `Dense index shape` を確認します。
3. 行数が何を表し、この設定で1,536列あることが何を意味するかを説明します。
4. `search` を読み、特にスコア計算、状態の判定、`seen` 集合 [set] を確認します。

記入： 行が表すもの： _____ 列が表すもの： _____

この小さなコーパスでは、全件を順位付けした後で利用条件に合う結果を選んでいきます。全件を評価しているため、適格な資料同士の順位は保たれます。本番環境で候補数を制限する近似検索 [approximate search] を使う場合は、候補を切り詰める前の適切な段階で条件を適用する必要があります。

Step 2.2：最初の質問の検索結果を読む

1. 最初は `QUERY = 'How can I extend my book loan?'` のまま実行します。貸出期間の延長方法を尋ねる質問です。
2. 両方式が返した出典IDと本文を読みます。
3. 最上位の箇所が、本当に貸出延長への回答を支えているかを判断します。関連する出典はD02です。
4. 質問を変更する前に結果を記録します。

Step 2.3：言い換えた質問を試す

1. 同じセルの `QUERY` を `How do I read academic publications away from campus?` に変更します。学外から学術刊行物を読む方法を尋ねています。
2. セルを再実行します。データとモデルの設定は変更しません。
3. 各方式の上位2件に、学外からの電子ジャーナル利用を扱うD08があるかを調べます。
4. なければ「上位2件に含まれない」と記録します。表示されていない順位を推測して記入しないでください。

質問	方式	最上位の出典	上位2件での関連出典の順位	質問への回答を支えられるか
貸出期間の延長	TF-IDF	_____	_____	_____

質問	方式	最上位の出典	上位2件での関連出典の順位	質問への回答を支えられるか
貸出期間の延長	Dense	_____	_____	_____
学外から学術刊行物を読む	TF-IDF	_____	_____	_____
学外から学術刊行物を読む	Dense	_____	_____	_____

考察： どの表現で、どちらの方式が役立ちましたか。同順位やベクトル検索の失敗も有効な観察結果です。2つの質問だけで、方式全体の優劣は決められません。

Step 2.4：旧版を含めた場合と除外した場合を比べる

1. `CURRENT_ONLY = False` で始まるセルを探します。
2. `False` のまま実行します。このセルは30日間の貸出延長が可能かを尋ねます。
3. 上位3件に旧版のD03が含まれるかを記録します。
4. `CURRENT_ONLY` だけを `True` に変更し、再実行します。
5. すべての結果が `status == 'current'` を満たし、D03が含まれないことを確認します。

設定	返された出典ID	D03はあるか	この結果から確認できること
<code>False</code>	_____	_____	_____
<code>True</code>	_____	_____	_____

Step 2.5：検索順位と利用条件の違いを記録する

同じセルの `reflections['lab2']` に検索順位と絞り込みの比較を書き、`CURRENT_ONLY = True` の状態で再実行します。

確認ポイント： スコアだけに頼らず、関連する本文を判断できること。既定の現行規程のみの条件では、D03が返されないことを確認します。後の回答生成でも、この条件を明示的に指定しています。

理解を確かめる問い： メタデータの条件を満たしていても、質問には答えられない箇所が返されることはありますか。実際の出力か、具体的に想定できる例で説明してください。

回答： _____

休憩・保存：55–60分

ノートブックを保存し、実行環境への接続を維持してください。実行環境が再起動した場合は、準備A・B、続いてLab 1～2を再実行して状態を作り直します。保存したノートブックの記述は残りますが、実行環境内の変数やメモリ内キャッシュ [in-memory cache] は失われることがあります。

Lab 3：根拠に基づく回答とガードレール

時間：60–85分・対応する章：第1～3章

課題： 資料に基づく回答を生成し、入力と出力を受け入れる条件、拒否する条件を確認します。コードの確認に5分、実験に15分、記録と話し合いに5分を使います。

実装前に押さえる概念

回答の根拠付け [grounding] とは、回答の主張が、渡された資料の内容から導けることです。**出典情報 [provenance]** は、その資料がどこから来たかを示します。出典への参照は役立ちますが、正しい出典IDがあるだけでは、主張の裏付けにはなりません。

構造化出力 [structured output] では、`answer`、`abstain`、`citations` のように、アプリケーションが検査できる項目を返します。JSONオブジェクトの形式が正しくても、主張が誤っている可能性があります。そのため、追加の検証が必要です。

回答保留 [abstention] は、根拠が足りないため回答しないことです。通信障害、API側の回答拒否 [API refusal]、未完了の応答、出力の根拠要件に違反したことによる拒否とは区別します。違いは `guardrail_status` で確認してください。

ガードレール [guardrail]	該当箇所	機能
入力の長さ・型	<code>validate_question</code>	空、文字列以外、長すぎる質問を拒否する
出典の利用条件	<code>search(..., current_only=True)</code>	旧版の出典を除外する
根拠資料の扱いを指示	<code>generate_grounded</code>	本文を命令ではなくデータとして扱わせる
応答の項目	<code>ANSWER_SCHEMA</code>	JSONの構造を定義する
出典と引用文	<code>validate_output</code>	渡した出典IDと原文に一致する引用を確認する

これらの検証は、有害内容の審査 [moderation]、個人を特定できる情報の検出 [PII detection]、テナントごとの権限管理 [tenant authorization] を実装するものではありません。また、回答のすべての主張が引用文から導けることを証明するものでもありません。

Step 3.1：リクエストと検証処理を追う

回答生成のセルを実行する前に、次の点をコードで確認します。

1. 検索のAPI呼び出しより前に、入力検証が行われること。
2. 質問と資料が、JSON形式のユーザーメッセージ [user message] にまとめられること。
3. 優先度の高い `instructions` に、資料本文は信頼できないデータ [untrusted data] として扱うよう記述されていること。

4. 回答する場合、出力スキーマ [output schema] が出典IDと引用文を要求すること。
5. 検証処理が、渡した資料にある出典IDと、その本文に完全一致する部分文字列 [substring] だけを引用として認めること。

予想：架空の出典IDを拒否するのは、どの検証処理でしょうか。_____

Step 3.2：現行の延長規程に基づく回答を生成する

1. ANSWER_SCHEMA = {...} で始まるセルを実行します。関数を定義した後、How many days can a student renew a book? と、延長できる日数を尋ねます。
2. 回答、guardrail_status、引用、取得した資料本文を読みます。
3. D02が裏付ける事実、すなわち追加14日間、1回のみ、他の利用者が予約している場合は延長不可を確認します。
4. 抜けている条件や、根拠のない追加情報がないかを調べます。検証を通過しただけで正解と判断しないでください。

確認項目	観察結果
生成された回答	_____
状態	_____
引用した出典と原文	_____
日数と1回の制限が正しいか	_____
予約時の例外が含まれるか	_____
根拠のない記述・不足している条件	_____

Step 3.3：資料では答えられない質問をする

1. 次の UNKNOWN_QUESTION で始まる実験セルを探します。
2. How deep is the university swimming pool? と、大学のプールの深さを尋ねていることを確認します。
3. 実行前にセル全体を読みます。Step 3.4で確認する、コードで結果を判定できる拒否テスト [deterministic rejection test] も含まれています。
4. セルを1回実行し、最初の出力行から、プールに関する回答と状態を記録します。
5. コーパスにプールの深さの情報がないことを確認します。abstained による回答保留と、出力拒否やAPI障害を区別してください。

観察した回答・状態： _____

Step 3.4：同じ実行で行われた拒否テストを確認する

直前のセルは、次の3つの不正な入力を、意図的にアプリケーションのコードへ渡しています。

1. 根拠資料として渡していないD999への引用。
2. D02に存在しない、99日間の延長を主張する引用文。

3. 500文字の上限を超える501文字の質問。

想定どおりに拒否されたことを示す3つのメッセージを読みます。`before` は、課金対象となるプールの質問を処理した後に記録したカウンターです。最後のアサーション `[assertion]` は、その後の3つの拒否テストでAPI呼び出しが増えていないことを確認します。

テスト	期待する動作	観察結果
架空の出典D999	引用を拒否する	_____
架空の99日間という引用	引用文を拒否する	_____
501文字の入力	検索・生成の前に拒否する	_____
3つのテストによるAPIカウンター	変化しない	_____

Step 3.5：確認できた範囲を明確にして考察を残す

実験セルの `reflections['lab3']` に、出典付きの回答、拒否結果を1つ、残っている制約を1つ記入します。編集したセルを実行して考察を反映してください。このときプールの質問も再実行されるため、生成リクエストがもう1回発生します。変更のないテキストの埋め込みはキャッシュから取得します。

確認ポイント： 回答が規程に裏付けられているかを確認し、回答保留とブロック `[blocking]` を区別し、3つの拒否テストの結果を確認できていますか。

理解を確かめる問い： 回答が「99日間」と述べながら、D02の実在する語句「14 days」を引用したとします。出典と引用文の検証を通過する可能性がありますか。どのような追加確認が必要でしょうか。

回答： _____

Lab 4：評価と攻撃を想定したテスト

時間：85–110分・対応する章：第6章。本番運用の考察は第4章も参照

課題： 正解ラベル `[label]` のある質問群で検索を比較し、命令を混入させた資料で生成モデルの動作を確かめます。指標の確認に5分、`k`の比較に8分、攻撃テストに7分、記録と話し合いに5分を使います。

実装前に押さえる概念

正解として指定した出典 `[gold source]` とは、人が質問との関連性を確認してラベルを付けた出典です。このノートブックではチャンク単位ではなく、重複のない出典文書単位で評価します。対象は回答可能な6つの質問で、それぞれに正解文書が1件あります。

指標	質問ごとの計算	分かること
適合率 <code>[Precision@k]</code>	取得した関連文書数 / <code>k</code>	返された文書のうち関連するものの割合

指標	質問ごとの計算	分かること
再現率 [Recall@k]	取得した関連文書数 / 正解文書の総数	必要と指定した根拠をどれだけ取得できたか
逆順位 [Reciprocal rank@k]	最初の関連文書の順位の逆数。上位k件になれば0	有用な根拠が上位に現れるか

ノートブックは、各指標を質問間で平均します。逆順位の平均が**平均逆順位 [Mean Reciprocal Rank, MRR@k]**です。出力の辞書 [dictionary] では `rr` と表示されます。資料では答えられない質問には正解出典がなく、再現率の分母が0になるため、別に評価します。

プロンプトインジェクション [prompt injection] は、データとして渡された文章が、モデルへの指示として振る舞い、動作を変えようとするものです。この演習では、検索の後に無害な攻撃文字列を加え、生成モデルが信頼できない資料をどう扱うかを切り分けて調べます。取り込み時のスキャナー [ingestion scanner] や、考えられるすべての攻撃を評価するものではありません。

Step 4.1 : 1件を手計算する

取得したIDが `[A, C, B]`、正解IDが `{A, B}`、`k = 2` の場合を考えます。

1. 評価対象となる取得文書2件はどれですか。_____
2. そのうち関連文書は何件ですか。_____
3. 適合率を計算します。_____ / _____ = _____
4. 再現率を計算します。_____ / _____ = _____
5. 最初の関連文書の順位と、その逆数を求めます。_____

Lab 4の `EVAL_SET = [...]` で始まるセルを実行します。冒頭の評価用アサーションが、この手計算の例を確認します。自分の計算と照合し、分母を取り違えていないか確認してください。

Step 4.2 : 上位1件で評価する

1. 同じセルを `k = 1` の設定で実行します。
2. 各方式の集計値を下の表に記録します。
3. 質問ごとの正解IDと取得IDを読み、取りこぼしがあれば特定します。

Step 4.3 : 上位2件で評価する

1. `k` だけを `2` に変え、同じセルを再実行します。
2. Step 4.2で保存した数値を残したまま、両方式の新しい結果を記録します。
3. 実際の出典IDを使って、再現率や適合率が変わった理由を説明します。

方式	k	適合率 [Precision]	再現率 [Recall]	MRR (出力では rr)
TF-IDF	1	_____	_____	_____

方式	k	適合率 [Precision]	再現率 [Recall]	MRR（出力では rr）
Dense	1	_____	_____	_____
TF-IDF	2	_____	_____	_____
Dense	2	_____	_____	_____

各質問の正解出典は1件なので、上位2件に正解を含む場合の適合率は0.5です。これはラベルとkの設定による結果であり、それだけで検索器の性能が悪化したとは言えません。また、簡単な6問で満点を取っても、本番品質を確認したことにはなりません。

Step 4.4：命令を混入させた資料を試す

1. **Lab 4：攻撃用の資料と人による確認 [adversarial evidence and human review]** を読み、`poisoned_hits` で始まるセルを探します。
2. 元の取得結果をコピーしてから、`INJECTION_SUCCEEDED` を出力し、延長期間を99日間だと主張する命令を追加していることを確認します。
3. 望ましい結果を予想します。正しい14日間の規程に従うか、安全に回答を保留すべきです。ただし、すべてを拒否するより、正しく有用な回答を返せる方が、実用性を示せます。
4. 攻撃テストのセルを1回実行します。
5. 回答、状態、引用文、`guardrail_observations` を確認します。

攻撃テストの確認項目	観察結果
回答に判定用文字列 [marker] が現れたか	_____
回答は14日間、99日間、回答保留のどれか	_____
引用資料が実際の主張を裏付けているか	_____
安全性に加えて有用性もあったか	_____
この1件では確認できていないことは何か	_____

自動チェックは、大文字・小文字を区別して特定の文字列だけを探します。その文字列を出さずに回答内容を変える攻撃もあり得ます。真偽値 [Boolean] だけでなく意味を読んでください。`output_rejected` は出力のブロックであり、根拠付き回答の成功を示す値ではありません。

Step 4.5：人による確認を記録し、問題を1つ診断する

1. 次のコードセルで、`human_review` の4つの文字列を、実際の回答可能な質問、回答不能な質問、攻撃テストの出力に基づいて埋めます。回答に不足がなければ、不足項目の欄には `none` と記入します。
2. `reflections['lab4']` に、両方のkの結果、攻撃テストの観察、診断を1つ記入します。記録しなければ、エクスポート [export] には最後の指標計算だけが残ります。

3. この確認用セルを実行します。API呼び出しは発生しません。

診断の問い	回答
観察した失敗、または残っている制約	_____
段階：取り込み、検索、生成、検証のどこか	_____
診断を支える観察結果	_____
変更するとしたら何を1つ変えるか	_____
変更の評価に使う未使用の質問・攻撃	_____

確認ポイント： 指標の4行、攻撃結果の確認、人による判断、次のテスト案がそろっていますか。1つの攻撃文字列に耐えたことは、1件の観察結果であり、安全性全体の保証ではありません。

発展課題：基本演習の後に実施。 D01とD02の両方を必要とする質問を追加し、両文書を正解として再現率を測ります。調整に使った質問は開発用データ [development data] として扱い、最終評価には別の未使用データ [held-out data] を残してください。

提出と振り返り：110–120分

Step 5.1：記録がそろっているか確認する

- ☐ Lab 1：2つのチャンク数、境界の例、重なりによる利点と不利な点。
- ☐ Lab 2：2方式の検索結果、言い換え、絞り込みの有無の比較。
- ☐ Lab 3：根拠を確認した回答、回答不能な質問の観察、3つの拒否結果。
- ☐ Lab 4：k=1・k=2の指標、攻撃結果の確認、診断、次のテスト案。
- ☐ reflections の4項目と human_review の4項目を記入し、それぞれのセルを実行済み。

Step 5.2：成果物を出力する

- Python解説：レポートの出力 [report export]** の下のセルを実行します。
- `reflections complete: True` と表示されることを確認します。これは記入の有無の確認であり、考察の質の評価ではありません。
- `False` の場合は不足項目を埋め、該当セルを再実行してから、もう一度出力します。
- `rag_workshop_report.json` をダウンロードし、変更済みノートブックもColabの **File** メニューから保存・ダウンロードします。
- 講師が指定した方法で両方を提出します。記録用シートの観察結果も、ノートブックのテキストセルに残してください。

JSONには、指定したモデル出力、指標、使用量、考察項目が含まれます。テキストセルの記録用シートは自動では含まれません。こちらは提出するノートブックに保存されます。

Step 5.3：1分で説明できるようにまとめる

観察結果を使って、次の文を完成させてください。

最も重要だと考えた失敗、または制約は _____ です。

原因を _____ と考えたのは、 _____ を確認したためです。

_____ を変更し、 _____ で効果を評価します。

評価方法： 各演習で、実験の記録に1点、その記録に基づく解釈に1点、合計8点です。モデルが失敗しても、適切に診断できれば評価されます。コードが正常終了しただけでは、理解を示したことにはなりません。

トラブルシューティング早見表

症状	次に行うこと
キーが見つからない・HTTP 401	シークレット名とノートブックのアクセス設定を確認する
HTTP 403・404	指定モデルの利用権限を講師と確認する
HTTP 429	利用枠・呼び出し頻度の制限 [rate limit] を確認してから手動で再試行する
タイムアウト [timeout]	接続を調べ、原因を確認してから1回再試行する。連続実行で解決しようとしな
再接続後に NameError	準備と、未定義のオブジェクトを作る前の演習を再実行する
文字列を編集しても反映されない	レポートを出力する前に、編集したセルを実行する
output_rejected	出典と引用の要件を確認する。引用を言い換えると拒否される場合がある
complete=False	すべての考察・確認項目を埋め、該当セルを実行する

次の学習につなげる

第2章では文書解析 [parsing] と永続的なベクトル保存 [persistent vector storage]、第3章では高度な検索とガードレールを学びます。第4章と第6章は本番運用と評価を扱います。第5・7・8・9章のマネージドサービス、エージェント、マルチモーダルデータ、知識グラフは、別の演習で取り組みます。

実装の詳しい説明は[日本語のPython解説](#)、教材とAPIの公式資料は[参考資料](#)を参照してください。元の9章分の教材が発展コースに当たり、本書は2時間で取り組む基礎実践編です。