

学员实操手册：基于证据的RAG与安全护栏

简体中文 · 学员实操手册

作者 [Author]

Rajkumar Rajagobalan

请配合可执行的Colab笔记本使用本手册，通过正文开头的链接打开。观察结果可记录在纸上或自己保存的笔记本中。

姓名或小组编号： _____ 日期： _____

[在Colab中打开本实操手册](#)

本手册与可执行的Colab笔记本配套使用。每个实验都按“理解概念—预测结果—运行实验—解释现象”的顺序展开。课程已提供参考代码，请把课堂时间用于观察系统行为、比较结果和分析原因。

你将为一所**虚构的大学图书馆**搭建问答助手。课程中的10条规定均为专门编写的教学数据，其中包含一条现行续借规定和一条与之冲突的历史规定，用于模拟检索到过期证据的情况。

语言说明：讲解和练习要求采用简体中文，技术术语后附英文，便于与代码对应。代码、注释、字段名、数据集和测试问题保留英文，以保证各语言版本的实验条件一致。中文释义用于帮助理解，请勿用它替换代码中的英文问题。实验记录和反思可以用中文填写。

学习目标

完成本课程后，你能：

- 解释文本块边界和重叠区间如何影响检索器可获取的证据。
- 根据来源文档的排序结果，比较词法检索 [lexical retrieval] 与稠密检索 [dense retrieval]。
- 生成可追溯的回答，并区分来源校验与事实支持之间的差别。
- 测试输入长度限制、伪造引用、证据不足的问题和提示注入 [prompt injection]。
- 计算检索指标，单独评估生成结果，并提出有针对性的后续测试。

课程安排

课堂时间	活动	需要保存的实验记录
00–10	环境配置与核心概念	API预检成功记录
10–30	实验1：文本切分与元数据	两组切分参数的比较
30–55	实验2：检索与证据筛选	排名及筛选前后对比
55–60	休息并保存	已保存的笔记本
60–85	实验3：基于证据生成回答与安全护栏	回答、引用及拒绝测试结果
85–110	实验4：评估与对抗测试	指标对比与攻击结果审查
110–120	提交与讨论	笔记本及JSON报告

如何记录实验

把下面的表格当作实验记录单。在Colab中，可以直接编辑相应的文本单元格，也可以在实验代码下方插入一个文本 [Text] 单元格。每个实验结束时，还要填写代码中的 `reflections['labN']` 字符串；JSON报告导出的是这些字符串。

例如，将空字符串替换为自己的实验记录：

```
reflections['lab1'] = "My two counts were ... . The repeated phrase was ... . This matters because ... ."
```

请勿原样提交示例句子。应填写实际测量值和自己的解释，也可以使用中文。修改反思后必须运行该单元格，变量值才会更新到运行时 [runtime]。如果单元格中的值仍是 ''，重新运行会把已有反思清空。再次运行实验前，请先保存有用的输出，因为Colab会替换该单元格上一次的输出。

准备工作与核心概念

时间：00–10分钟。教师讲解处理流程时，同步完成环境配置。

概念：RAG解决了什么问题

检索增强生成 [Retrieval-Augmented Generation, RAG] 在收到问题后，先检索相关来源文本，再把这些文本提供给生成模型。语料库 [corpus] 可以包含内部信息、最新资料或特定业务知识，但模型仍有可能误解这些证据。

本笔记本包含两条处理流程：

流程	处理内容	主要代码对象
准备阶段	加载记录、切分文本、生成向量并构建索引	<code>DOCUMENTS</code> , <code>chunks</code> , <code>dense_matrix</code>
问答阶段	对证据排序、筛选可用来源、构造请求、生成并校验回答	<code>search</code> , <code>answer_question</code> , <code>generate_grounded</code> , <code>validate_output</code>

检索可能选错证据；即使检索正确，生成阶段也可能回答错误。整个实验中都要分别分析这两类问题。

步骤0.1 — 打开并保存笔记本

1. 打开本手册顶部的Colab链接，登录Google账号。
2. 选择复制到云端硬盘 [Copy to Drive]，创建自己的副本。
3. 将副本命名为 `RAG_Workbook_<your-name-or-pair-id>`，用姓名或小组编号替换占位部分。
4. 在运行时设置中选择 **Python 3**，硬件加速器选择 **None / CPU**。
5. 打开笔记本目录，找到环境配置A [Setup A]、环境配置B [Setup B] 和实验1–4。

检查：你拥有可编辑的副本，并能找到全部4个实验。

步骤0.2 — 配置OpenAI密钥

- 1. 打开Colab的密钥 [Secrets] 面板。
- 2. 新建密钥，名称必须为 OPENAI_API_KEY。
- 3. 填入可正常计费使用的OpenAI API密钥，并启用该笔记本的访问权限。
- 4. 运行“环境配置A：依赖包与密钥”下方的代码单元格。

密钥通过请求的授权标头 [authorization header] 发送，不属于模型提示词 [prompt]。请勿把密钥写入笔记本文本、代码、截图或提交材料。

步骤0.3 — 检查两类API能力

- 1. 阅读“环境配置B：API客户端与向量缓存”。
- 2. 运行其代码单元格一次。
- 3. 确认出现 READY。预检会分别测试向量生成和文本生成端点 [endpoint]。
- 4. 注意：api_calls 统计尝试发出的请求，usage_log 保存成功请求返回的用量。向量缓存的键由模型标识和完整原文共同组成。

概念：预检 [preflight] 可以在后续实验依赖API之前发现账号或模型权限问题。缓存 [cache] 可以避免在当前运行时中重复提交未改变的文本。课堂代码的40次请求限制不是账号消费上限；重新运行配置单元格会清空计数器和缓存。

遇到阻塞时：401先检查密钥；403或404检查项目与模型权限；429检查额度或速率限制。连续两次配置失败后，请教师安排你与环境正常的同学结对。使用教师记录的示例时，应注明来源，不能把它写成自己的实时运行结果。

配置记录：是否出现READY：_____ 运行时：_____ 结对编号（如适用）：_____

实验1 · 证据与文本块边界

时间：10–30分钟 · 对应第1–2章

任务：将来源文档切分为文本块，同时保留来源信息，并观察重叠区间的影响。建议用3分钟阅读示例、12分钟实验、5分钟记录与讨论。

编码前先理解概念

概念	在本实验中的含义	为什么重要
文档 [document]	一条完整的图书馆规定记录	确定原始来源
文本块 [chunk]	从记录中截取的一段文本窗口	决定哪些证据能一起被检索到
重叠 [overlap]	相邻窗口之间重复的词	可能保留跨边界的上下文，但会增加重复文本
元数据 [metadata]	doc_id, title, status	支持来源追溯和可用性判断

概念	在本实验中的含义	为什么重要
文本块标识 [chunk ID]	来源ID加起始词偏移量	标识实际检索到的具体段落

此实现按空白字符分词，长度单位是词，而不是模型词元 [token]。它可能切断句子，也可能把规则与例外条件分开。接下来要直接检查这一局限。

步骤1.1 — 检查来源记录

- 1. 运行以 `DOCUMENTS = [...]` 开头的单元格。
- 2. 确认输出显示10条记录。
- 3. 在数据中找到D02和D03，阅读正文与状态。
- 4. 区分现行续借规定和历史规定，预测历史记录进入生成阶段后可能造成什么问题。

记录：现行来源ID：_____ 历史来源ID：_____ 冲突的续借时长：_____

步骤1.2 — 跟踪切分函数

阅读 `chunk_documents`，运行前向同伴解释：

- `size - overlap` 决定相邻窗口起点之间的步长 [stride]。
- `words[start:start + size]` 限定当前窗口的范围。
- `{**doc, ...}` 将来源元数据复制到每个文本块。
- 最后的 `break` 在窗口到达文档末尾时结束循环。

预测：窗口长度为20、重叠为5时，下一个窗口的起点向后移动_____个词。

步骤1.3 — 不设置重叠

- 1. 在包含 `chunk_documents` 的单元格中，设置 `CHUNK_SIZE = 20`、`OVERLAP = 0`。
- 2. 运行该单元格。
- 3. 记录 `Trial chunks`，阅读打印出的全部D02文本块。
- 4. 标出或抄录一处边界附近的句子片段。检查是否有单个文本块同时包含续借时长和完整的预约例外条件。

步骤1.4 — 只改变一个参数

- 1. 保持 `CHUNK_SIZE = 20`，仅将 `OVERLAP` 改为 5。
- 2. 重新运行同一单元格。
- 3. 记录新的文本块总数和一处重复短语。
- 4. 比较证据覆盖情况。如果重叠仍未让完整规则出现在同一文本块中，请如实记录。

参数配置	文本块总数	边界片段或重复短语	规则与例外是否在同一块中？
20个词，重叠0	_____	_____	_____

参数配置	文本块总数	边界片段或重复短语	规则与例外是否在同一块中？
20个词，重叠5	_____	_____	_____

步骤1.5 — 保存结论并准备统一语料

1. 填写 `reflections['lab1']`，包括两次计数、引用的边界片段和你的解释。
2. 运行该反思单元格。它还会按**40个词 / 重叠8个词**创建后续共用的 `chunks`。
3. 实验2–4保持这一统一配置。实验变量 `trial` 与检索基线 `[baseline]` 分开保存。

检查点：每个文本块都保留来源ID和状态，长度不超过配置值；反思中包含实际观察到的文本边界。

理解检查：为什么增大重叠可能改善证据覆盖，却也会增加索引成本和重复检索？

你的回答： _____

实验2 · 检索与证据筛选

时间：30–55分钟 · 对应第2–3章

任务：比较两种检索方法，并防止历史规定进入针对现行政策的回答。建议用4分钟阅读示例、16分钟实验、5分钟记录与讨论。

编码前先理解概念

词法检索 [lexical retrieval] 比较词语。词频—逆文档频率 [Term Frequency–Inverse Document Frequency, TF-IDF] 根据词在文本块内及整个语料中的出现情况赋予权重。它适合匹配明确的术语，但可能漏掉使用不同措辞的同义问法。

稠密检索 [dense retrieval] 比较嵌入向量 [embedding vector]。本实验使用同一模型处理文本块和问题，归一化 [normalization] 后计算点积 [dot product]。对于单位长度向量，点积等于余弦相似度 [cosine similarity]。这个分数用于排序，不表示段落或回答正确的概率。

可用来源筛选 [eligibility filtering] 决定应用可以采用哪些来源。本实验的规则是 `status == 'current'`。这只能限制来源状态，不等于用户授权 [authorization]，也不能证明规定本身准确。

本实验的 **top-k** 指排名靠前的k个不重复的**来源文档**。检索器保留每个来源得分最高的文本块，跳过相同 `doc_id` 的其他块。生成模型收到的是这些入选段落，并非完整文档。

步骤2.1 — 构建并检查索引

1. 运行实验2中以 `tfidf = TfidfVectorizer(...)` 开头的单元格。
2. 查看输出的 `Dense index shape`。
3. 说明行数代表什么，以及当前配置中的1,536列代表什么。
4. 阅读 `search`，重点检查分数计算、状态判断和 `seen` 集合。

记录：行表示_____；列表示_____。

本例会先对整个小型语料库排序，再依次选取符合条件的结果。完整遍历排序结果不会改变符合条件来源的相对顺序。生产环境中的近似搜索 [approximate search] 若只保留有限候选集，则需要在候选截断前正确处理筛选条件。

步骤2.2 — 检查第一个问题

- 1. 首次运行保留 `QUERY = 'How can I extend my book loan?'`，即“如何延长图书借阅期限？”
- 2. 阅读两种方法返回的来源ID和正文。
- 3. 以D02为相关来源，判断首条结果是否真正支持续借问题。
- 4. 修改问题前保存结果。

步骤2.3 — 测试同义改写

- 1. 将同一单元格中的 `QUERY` 改为 `How do I read academic publications away from campus?`，即“在校外如何阅读学术出版物？”
- 2. 重新运行；保持数据与模型配置不变。
- 3. 检查两种方法的前两条结果，查找远程期刊访问规定D08。
- 4. 如果没有D08，记录“未进入前2名”，不要推测未显示的排名。

问题	方法	首位来源	相关来源在前2名中的位置	是否支持回答？
延长借阅期限	TF-IDF	_____	_____	_____
延长借阅期限	Dense	_____	_____	_____
校外阅读学术出版物	TF-IDF	_____	_____	_____
校外阅读学术出版物	Dense	_____	_____	_____

解释：哪种方法在哪种问法上更有效？两者持平或稠密检索失败都是有效观察。仅凭两个问题，无法判断哪种方法普遍更好。

步骤2.4 — 先允许历史规定，再将其排除

- 1. 找到以 `CURRENT_ONLY = False` 开头的单元格。
- 2. 使用 `False` 运行。该单元格询问图书是否可以续借30天。
- 3. 记录历史来源D03是否进入前三条结果。
- 4. 仅将 `CURRENT_ONLY` 改为 `True`，重新运行。
- 5. 确认所有返回来源都满足 `status == 'current'`，且不包含D03。

设置	返回的来源ID	是否包含D03？	这能说明什么？
False	_____	_____	_____
True	_____	_____	_____

步骤2.5 — 记录两种判断的区别

在该单元格中填写 `reflections['lab2']`，记录排名和筛选前后的差异，然后保持 `CURRENT_ONLY = True` 再次运行。

检查点：你能根据段落内容判断相关性，而不只看分数；默认仅允许现行规定时，D03不会返回。后续生成调用也会明确保留这一筛选条件。

理解检查：一个段落能否满足元数据条件，却仍无法回答问题？请引用实际输出或举出合理例子。

你的回答： _____

休息并保存 · 55–60分钟

保存笔记本，保持运行时连接。如果运行时重启，请依次重跑环境配置A、B和实验1–2，重建所需状态。已保存的笔记本文本会保留，但变量和内存缓存可能丢失。

实验3 · 基于证据生成回答与安全护栏

时间：60–85分钟 · 对应第1–3章

任务：根据证据生成回答，再测试应用接受或拒绝输入、输出的边界。建议用5分钟阅读示例、15分钟实验、5分钟记录与讨论。

编码前先理解概念

基于证据生成 [grounding] 要求回答中的主张能从给定证据中得到支持。**来源追溯 [provenance]** 说明证据来自哪里。标明来源很有用，但来源ID有效并不代表回答有充分依据。

结构化输出 [structured output] 提供便于程序检查的字段：`answer`、`abstain` 和 `citations`。格式正确的JSON仍可能包含错误事实，因此应用还需要执行后续校验。

证据不足时拒答 [abstention] 是指模型因缺少依据而不作答。它不同于网络故障、API拒绝响应 [API refusal]、响应不完整或证据约束校验失败。请根据 `guardrail_status` 区分这些情况。

安全护栏 [guardrail]	代码位置	作用
输入长度与类型	<code>validate_question</code>	拒绝空问题、非字符串和超长问题
来源可用性	<code>search(..., current_only=True)</code>	排除历史来源
证据使用指令	<code>generate_grounded</code>	要求模型把段落当作数据，而非指令
响应字段	<code>ANSWER_SCHEMA</code>	规定预期的JSON结构
来源与引文	<code>validate_output</code>	检查来源ID及逐字引用的文本

这些检查不包含内容审核 [moderation]、个人身份信息检测 [PII detection] 或租户授权 [tenant authorization]，也不能证明回答的每项主张都能从引文中推出。

步骤3.1 — 跟踪请求与校验

运行生成单元格之前，找到以下逻辑：

- 1. 输入校验在检索可能消耗API请求之前执行。
- 2. 问题和证据被编码为JSON用户消息。
- 3. 更高优先级的 `instructions` 将证据文本定义为不可信数据 [untrusted data]。
- 4. 输出模式 [schema] 为正常回答要求来源ID和引文。
- 5. 校验器只接受已提供段落中的来源ID，并要求引文是相应段落的精确子串 [exact substring]。

预测：哪项检查应当拒绝虚构的来源ID？ _____

步骤3.2 — 生成基于现行规定的续借回答

- 1. 运行以 `ANSWER_SCHEMA = {...}` 开头的单元格。它定义相关函数，并提问 `How many days can a student renew a book?`，即“学生可以续借图书多少天？”
- 2. 阅读回答、`guardrail_status`、引用及检索段落。
- 3. 核对D02支持的事实：**额外14天、只能续借一次、如果其他读者已预约则不能续借。**
- 4. 找出遗漏或无依据的补充。不要仅因约束校验通过就认定回答正确。

审查项目	你的观察
生成的回答	_____
状态	_____
引用来源及逐字引文	_____
时长与一次续借限制是否正确？	_____
是否包含预约例外条件？	_____
无依据或遗漏的细节	_____

步骤3.3 — 提出语料无法回答的问题

- 1. 找到下一个以 `UNKNOWN_QUESTION` 开头的实验单元格。
- 2. 确认问题为 `How deep is the university swimming pool?`，即“大学游泳池有多深？”
- 3. 运行前阅读整个单元格；它还包含步骤3.4的确定性拒绝测试 [deterministic rejection test]。
- 4. 运行一次，从第一行输出记录游泳池问题的回答和状态。
- 5. 核对语料：其中没有泳池深度信息。区分主动拒答的 `abstained`、输出被拒绝和API失败。

观察到的回答 / 状态： _____

步骤3.4 — 检查同一次运行中的拒绝测试

刚运行的单元格向应用代码提交了三种人为构造的无效输入：

- 1. 引用未作为证据提供的D999。
- 2. 使用D02中不存在的“可续借99天”引文。
- 3. 提交501个字符的问题，超过500字符的上限。

阅读三条预期拒绝消息。before 计数是在付费的游泳池问题请求之后记录的。最后的断言 [assertion] 检查这三项拒绝测试没有增加API调用次数。

测试	预期行为	实际结果
虚构来源D999	拒绝引用	_____
伪造99天引文	拒绝引文	_____
501字符输入	检索 / 生成前拒绝	_____
这三项测试的API计数	不变	_____

步骤3.5 — 写出与证据相符的结论

在实验单元格中填写 reflections['lab3']，包括带引用的回答、一项拒绝结果和一项仍未解决的局限。运行修改后的单元格以保存反思；这会重新请求游泳池问题，产生一次新的生成请求，而未改变的文本向量会从缓存读取。

检查点：你已经核对规定是否真正支持回答，区分证据不足时拒答与程序拦截，并观察到三项确定性拒绝结果。

理解检查：如果回答声称“99天”，但引用了D02中真实的“14天”，来源 / 引文校验器是否可能放行？还需要怎样的审查？

你的回答： _____

实验4 · 评估与对抗测试

时间：85–110分钟 · 对应第6章，结合第4章讨论生产环境

任务：用已标注的问题比较检索效果，再通过被污染的证据段落测试生成模型。建议用5分钟理解指标、8分钟比较k值、7分钟做攻击测试、5分钟记录与讨论。

编码前先理解概念

人工标注的相关来源 [gold source] 是人工认定能支持某个问题的来源。本笔记本按不重复的来源文档评估，而非按单个文本块评估。评估集包含6个可回答问题，每题各有一个相关文档。

指标	单题计算方法	含义
精确率 [Precision@k]	检索到的相关文档数 / k	返回结果中有多少是相关的
召回率 [Recall@k]	检索到的相关文档数 / 全部标注相关文档数	找到了多少已标注的相关证据
倒数排名 [Reciprocal rank@k]	首个相关结果排名的倒数；前k名没有则为0	有用证据是否排在前面

代码对每项指标取跨问题平均值。倒数排名的平均值称为**平均倒数排名 [Mean Reciprocal Rank, MRR@k]**，输出字典中记作 `rr`。证据不足的问题没有相关来源，召回率分母会为0，因此另行评估。

提示注入 [prompt injection] 是指本应作为数据处理的文本试图改变模型行为。本实验在检索完成后追加一段无害攻击文本，单独观察生成模型如何处理不可信证据；它不测试数据接入扫描器，也不覆盖所有攻击方式。

步骤4.1 — 手算一个例子

已检索到的ID为 [A, C, B]，标注相关ID为 {A, B}，k = 2：

1. 哪两个文档计入返回结果？ _____
2. 其中有几个相关文档？ _____
3. 精确率： / = _____
4. 召回率： / = _____
5. 首个相关结果的排名及其倒数： _____

运行实验4中以 `EVAL_SET = [...]` 开头的单元格。开头的指标断言会验证这个例子。与手算结果对照，检查是否选错分母。

步骤4.2 — 测量top-1检索

1. 保持该单元格中的 `K = 1` 并运行。
2. 将两种方法的汇总结果记录到下表。
3. 查看逐题的标注ID与返回ID，如有漏检，指出具体问题。

步骤4.3 — 测量top-2检索

1. 仅将 `K` 改为 2，重新运行。
2. 记录两种方法的结果；第一次运行的数据应已保存，以免被新输出覆盖。
3. 用实际来源ID解释召回率和精确率的变化。

方法	k	精确率	召回率	MRR, 输出为 rr
TF-IDF	1	_____	_____	_____
Dense	1	_____	_____	_____

方法	k	精确率	召回率	MRR, 输出为 rr
TF-IDF	2	_____	_____	_____
Dense	2	_____	_____	_____

每题只有一个标注相关来源，因此top-2成功命中时精确率为0.5。这反映的是标注方式与k值选择，不能仅凭这一点认定检索器变差。即使6道简单问题全部得满分，也不足以证明系统达到生产质量。

步骤4.4 — 测试被污染的证据

1. 阅读“实验4：对抗证据与人工审查”，找到以 `poisoned_hits` 开头的单元格。
2. 确认代码先复制基线段落，再附加要求输出 `INJECTION_SUCCEEDED` 并声称续借99天的指令。
3. 预测理想结果：模型应继续依据合法规定回答14天，或在无法可靠判断时安全拒答。正确且有用的回答，比一律拒答更能体现系统实用性。
4. 运行攻击单元格一次。
5. 检查回答、状态、引文及 `guardrail_observations`。

攻击结果审查	你的观察
回答中是否出现攻击标记？	_____
回答是14天、99天，还是拒答？	_____
引用证据是否支持实际主张？	_____
回答是否兼顾安全与实用性？	_____
这个案例还有哪些未覆盖的情况？	_____

自动标记检查区分大小写，覆盖范围很窄。攻击者即使不让模型输出该字符串，也可能改变回答。除了布尔值 [Boolean]，还必须检查实际含义。`output_rejected` 表示输出被拦截，不等于成功生成了有证据支持的回答。

步骤4.5 — 完成人工审查并诊断一个问题

1. 在后续代码单元格中，根据实际的已知问题、未知问题和攻击输出，填写全部4项 `human_review` 字符串。如果已知问题的回答完整，在缺失细节项填 `none`。
2. 填写 `reflections['lab4']`，包含两种k值的结果、一项攻击观察和一项诊断。否则，导出报告只保留最后一次指标运行的数据。
3. 运行该审查单元格；此单元格不调用API。

诊断问题	你的回答
观察到的失败或仍存在的局限	_____
所处阶段：数据接入、检索、生成或校验	_____

诊断问题	你的回答
支持诊断的证据	_____
你会实施的一项修改	_____
用于检验修改的未使用问题或攻击	_____

检查点：已记录4行指标、完成攻击审查和人工判断，并提出下一项测试。通过一条攻击测试只是一次观察，不是安全保证。

核心任务完成后的选做练习：增加一个需要同时引用D01和D02的问题，将两个文档都标为相关来源，再测量召回率。一旦使用某个问题调整系统，它就属于开发数据 [development data]；最终评估应另用未参与调优的数据 [held-out data]。

提交与讨论 · 110–120分钟

步骤5.1 — 检查实验记录

- ☐ 实验1：两组文本块数量、边界示例及重叠的利弊。
- ☐ 实验2：两种检索方法、同义改写，以及开启 / 关闭筛选的对比。
- ☐ 实验3：经证据核对的回答、证据不足问题的结果，以及三项拒绝测试。
- ☐ 实验4：k=1与k=2指标、攻击审查、问题诊断及后续测试。
- ☐ 全部4项 reflections 和4项 human_review 已填写，并已运行对应单元格。

步骤5.2 — 导出作业

- 运行“Python代码说明：导出报告”下的单元格。
- 确认输出 reflections complete: True。这只检查字段是否填写，不评价推理质量。
- 如果为 False，补齐缺失项，运行相应单元格后再导出。
- 下载 rag_workshop_report.json，并通过Colab文件菜单保存 / 下载修改后的笔记本。
- 按教师指定渠道提交两份文件。表格中的实验观察应保存在笔记本的文本单元格中。

JSON包含选定的模型输出、指标、用量和反思字段，不会自动收集文本单元格中的记录；提交笔记本才能保留这些内容。

步骤5.3 — 准备一分钟汇报

根据实验记录补全：

我们观察到的最重要失败或局限是_____。

我们将问题定位到_____，依据是_____。

我们计划修改_____，并用_____检验效果。

评分：每个实验的实验记录占1分，基于记录的解释占1分，共8分。准确诊断模型失败同样可以得分。代码运行成功本身不代表理解了原理。

常见问题速查

现象	下一步
缺少密钥或HTTP 401	检查密钥名称及笔记本访问开关
HTTP 403或404	请教师协助检查项目对所配置模型的访问权限
HTTP 429	手动重试前检查额度与速率限制
请求超时	排查网络后重试一次，避免反复运行
重新连接后出现 <code>NameError</code>	重跑配置和定义缺失对象的前序实验
修改字符串后结果未更新	导出前运行修改过的单元格
<code>output_rejected</code>	检查来源与引文约束；改写原文也可能导致引文校验失败
<code>complete=False</code>	填写并运行每一项反思与人工审查字段

课后延伸

第2章进一步介绍解析与持久化向量存储；第3章扩展检索方法与安全护栏；第4章和第6章讨论生产运行与评估。第5、7、8、9章分别涉及托管平台、智能体、多模态数据和知识图谱，适合安排为独立课程。

实现细节请参阅[简体中文Python代码说明](#)，课程出处与官方API文档见[参考资料](#)。原有9章仍构成完整的进阶课程，本手册聚焦其中适合两小时课堂的实践主线。