

第2回・RAGプラットフォーム、AIエージェント、マルチモーダルRAG、知識グラフ

日本語・受講者用ハンズオンワークブック

著者 [Author]

Rajkumar Rajagobalan

実行可能なColabノートブックと併せて使用してください。冒頭のリンクから開けます。観察結果は紙面または保存したノートブックに記録してください。

2時間・Lab 5～8・Python中級～上級者向け・Google Colab+OpenAI

氏名・ペアID：_____ 実施日：_____

[日本語版をColabで開く](#)

架空の大学のものづくり施設を案内するアシスタントを作ります。規程、部屋の空き時間、グラフ画像、人物・組織、関係データは、すべて授業用に作成した架空の情報です。第1回で学んだ根拠資料 [evidence] とガードレール [guardrail] の考え方を発展させますが、実行環境は新しく作り、第1回の変数は使いません。

対応する原教材は第5・7・8・9章です。本授業では順に **Lab 5・6・7・8** と呼びます。プラットフォームの演習では、Vectaraを扱う章のライフサイクルの考え方をOpenAIのマネージド検索 [managed retrieval] に応用します。知識グラフはメモリ上で扱い、Neo4jやMicrosoft GraphRAGのインストールは行いません。

英語との対応：技術用語は英語を角括弧で併記します。コード、コメント、変数名、モデル名、質問文、データ本文は英語版と共通です。入力を翻訳すると検索実験の条件も変わるため、指定された英語を使ってください。観察結果と考察は日本語で記入できます。

進行と記録

開始からの時間	内容	残す記録
00–10分	準備・事前確認	READY、モデル名、リソース情報の保存先
10–35分	Lab 5：RAGプラットフォーム	索引の準備完了、絞り込み結果、出典付き回答
35–60分	Lab 6：AIエージェント	実際のツール呼び出し履歴と境界テスト
60–65分	休憩	保存済みノートブックと管理ファイル
65–85分	Lab 7：マルチモーダルRAG	取得画像、説明文のみ／画像付きの比較
85–110分	Lab 8：知識グラフ	2ホップの経路、候補の絞り込み、資格取消の結果
110–120分	確認・削除・提出	ノートブック、JSONレポート、削除完了の記録

各演習は**予想→実行→観察→説明**の順に進めます。表はColabのテキストセル [text cell] を編集するか、別のTextセルを追加して記入してください。最後の考察セルに入力した文字列はJSONへ出力されますが、テキストセルの表はノートブックにしか残りません。期待値を実測値として書かず、失敗した場合も根拠を示して診断してください。

準備・00-10分

Step 0.1：自分のコピーを作り、設定する

1. Colabで **Copy to Drive** を選び、`RAG_Session2_<name-or-pair>` の名前で保存します。
2. Python 3、CPUを使用します。GPU、データベースサーバー、追加サービスのアカウントは不要です。
3. **Secrets** に `OPENAI_API_KEY` を登録し、ノートブックからのアクセスを許可します。指定モデルに加え、FilesとVector Storesの利用権限が必要です。
4. 次の設定コードを読んで1回実行し、`READY` と事前確認の回答を確認します。API利用料金は自分のOpenAIプロジェクトに請求されます。

Step 0.2：保存される状態を理解する

`api` はPython標準ライブラリで作ったHTTPクライアント [HTTP client] です。送信先をOpenAIの固定アドレスと授業用エンドポイントに制限し、送信前に試行を記録します。成功・失敗の両方で所要時間を測りますが、認証ヘッダーは記録しません。タイムアウト [timeout] は45秒、メモリ上の試行回数は100回までです。上限後も削除用のDELETEは使えます。自動再試行 [automatic retry] は行いません。

`embed` は未処理の文字列をまとめて送り、応答の行を入力順に戻し、1,536次元を確認して正規化 [normalization] します。キャッシュ [cache] のキーを (`model`, `exact_text`) とすることで、別モデルや変更済みテキストの結果を誤用しません。`grounded` は質問と出典ID付きの資料を送り、必要に応じて画像を追加します。出力項目は `answer`、`abstain`、`sources` です。`check_answer` は型と出典IDの許可リスト [allowlist] を検証しますが、**主張が資料から導けること [entailment] は検証しません**。人による確認が必要です。

`session2_resources.json` は、この実行で作成した実行ID、ベクトルストアID、ファイルIDだけを記録する管理ファイル [resource ledger] です。作成が成功するたびに更新するため、中断後は記録済みのリソースを再作成せず再開できます。同じ実行環境で設定セルを再実行してもカウンターは保持されますが、環境をリセットすると失われます。管理ファイルはカーネル再起動後に残る場合もありますが、仮想マシン [VM] が破棄されると消えます。Lab 5でダウンロードしてください。APIキーはこのファイル、コード、画面写真、提出物に含めません。

ベクトルストアには、最終利用から1日後の有効期限 [expiry] を設定します。ただし、**元のアップロード済みFilesオブジェクトは別途削除が必要です**。コードの回数制限はアカウントの支出上限ではありません。`store=False` はResponsesの保存を制御する設定であり、アカウント全体のデータ保持を無効にするものではありません。

Step 0.3：準備で止まった場合

401はキー、403・404はプロジェクト・モデル・Filesの権限、429は利用枠と呼び出し頻度の制限 [rate limit] を確認します。2回目も準備に失敗したら、実行できる受講者とペアになり、共同実行や記録済みの結果であることを明記します。リソース作成中のタイムアウトは、作成の成否が不明なため、安易に再実行せず末尾の復旧手順を使ってください。Lab 6～8に必要なのは設定と `POLICIES` の定義であり、ホストされた検索サービスは呼び出しません。

記録：READY _____ モデル名 _____ 管理ファイルの保存先 _____

`grounded` は `guardrail_status` に `contract_passed`、`abstained`、`output_rejected`、`api_refusal`、`incomplete` を返します。拒否した構造化出力は診断用の `raw_output` に残しますが、受理された回答として扱ってはいけません。例えば、回答保留なのに出典を付けた出力は拒否します。通信・HTTP障害は明示的なエラ

ーになります。READYはAPI呼び出しが完了したことを示すため、事前確認の状態も読んでください。

Lab 5・マネージドRAGプラットフォーム

10–35分・原教材第5章・説明5分、実験15分、確認5分

概念：どこまでをサービスに任せるか

マネージド検索サービスは、アップロードしたテキストの解析 [parsing]、分割 [chunking]、埋め込み [embedding]、索引検索を担当します。一方、資料の品質、利用条件、回答指示、評価、権限、作成から削除までの管理はアプリケーション側の責任です。本演習は検索基盤をマネージド化し、回答生成を明示的に呼び出す構成です。Vectaraの全機能やハルシネーション修正APIと同等だと示すものではありません。

Step 5.1：4件の規程を読む

現行のP01と旧版のP02を探します。前者は2時間まで、後者は4時間までの予約を認めていました。P03は機器利用に必要な資格、P04は問い合わせ先を定めます。「four hours」を含む質問では、どの資料が取得されそうか予想してください。

Step 5.2：アップロードし、索引の完成を待つ

次のセルを実行します。upload_policy はマルチパート形式 [multipart form] の本文を組み立て、実行IDを付けた名前で送信します。Filesオブジェクトは元のバイト列を保持します。それをベクトルストア [vector store] に関連付けると索引作成が始まり、同時に source_id と status 属性を付けます。

prepare_platform は作成前に管理ファイルを確認します。ポーリング [polling] は file_counts を最大12回読み、未完了時は3秒待ちます。通信時間は別途加わります。indexing_pending なら管理ファイルを消さず同じセルを再実行します。2回試しても準備が終わらなければ、ペアの結果を使って次へ進みます。failed の場合は原因を調べ、未完成の索引を使って検索しないでください。

ダウンロードされた session2_resources.json は、削除完了まで保管します。ストアが存在することと、全ファイルの検索準備が整ったことは別です。

記録：完了ファイル数 _____ 状態 _____ 管理ファイルの保存確認 _____

Step 5.3：絞り込みの有無を比較する

platform_search を読みます。最大4件を要求し、指定時はファイル属性フィルター [attribute filter] を適用し、出典ID、状態、スコア、取得本文を保持します。返るのはサービス側のチャンクです。第1回の重複除去済み評価とは異なり、k件の異なる文書が返る保証はありません。

次のセルを実行します。Can a student book a makerspace room for four hours per day?、すなわち「学生は1日4時間予約できるか」に対して、絞り込みなしと現行規程のみの検索を行い、後者の資料から回答を生成します。

確認項目	観察結果
絞り込みなしのID・状態	_____

確認項目	観察結果
絞り込みありのID・状態	_____
絞り込み後の資料にP02がないか	_____
回答と引用した出典ID	_____
主張は現行P01と一致するか	_____

Step 5.4：結果を説明する

変更して再実行：4時間の質問の結果を保存し、`PLATFORM_QUESTION` を `What qualification does a team need to use equipment?`（機器利用に必要な資格は何か）に変更して、検索・生成セルを再実行します。P03が回答を裏付けるか確認してください。両方の質問と出典IDをテキスト欄と最後の考察に残します。`observations['lab5']` には最新の実行だけが残し、再実行ではAPI呼び出しが追加されます。

サービス側に移った責任と、アプリケーション側に残る責任を1つずつ挙げます。スコアは事実の正確さの確率ではありません。今回は信頼できるコードが授業用の属性を設定していますが、このフィルターだけでテナントごとの認可 `[authorization]` は実現できません。出典IDが正しくても、回答の時間が正しいとは限りません。

確認ポイント：4件の索引が完成し、絞り込み結果に旧版がなく、P01と回答を照合できたこと。絞り込みなしでもP02が出なければ、その事実を記録し、順位を作り上げないでください。

後で `reflections['lab5']` に、ID、回答が述べた時間、責任分担を書きます。

Lab 6・実行範囲を制限したAIエージェント

35–60分・原教材第7章・説明5分、実験15分、確認5分

概念：モデルが要求し、アプリケーションが実行する

エージェントループ `[agent loop]` は、質問とツール定義をモデルへ送り、関数呼び出し `[function call]` を検証し、許可された関数を実行し、対応する `call_id` とともに結果を返して処理を続けます。関数呼び出しはアプリケーションへの実行要求です。`eval` で実行すべきPythonコードではありません。

Step 6.1：読み取り専用ツールを確認する

`search_policy` は現行規程に対する単純なローカル語彙検索 `[lexical retrieval]` です。単語の重なりを使い、Lab 5のサービスは呼びません。`get_slots` は火曜日の固定の空き状況 `[snapshot]` を返します。どちらも予約は行いません。`dispatch` はモデルの厳密なスキーマ `[strict schema]` とは独立して、ツール名、引数のキー、許可された値を検証します。この再検証が実行境界を守ります。

`run_agent` の上限はツール実行3回、モデルとのやり取り4ラウンドです。`parallel_tool_calls=False` で履歴を追いやしくしますが、Python側は返されたすべての呼び出しを処理する構造です。ツール出力は元の `call_id` を付けて会話履歴に加えます。最終回答に許可する出典は、実際にツールが返した資料だけです。

Step 6.2：予想してから実際のループを動かす

AGENT_QUESTION は、予約時間の上限と、それに合うLabAの火曜日の空き時間を尋ねます。必要なツールと順序を予想し、セルを実行してください。status、最終回答、各履歴の引数・出典IDを読みます。モデルが別の順序を選んだ場合や上限に達した場合も、実際の結果を記録します。

項目	観察結果
予想したツールの順序	_____
実際のツールと引数	_____
最終状態・引用出典	_____
規程上の時間と条件に合う火曜日の枠	_____
予約済みだと誤って述べていないか	_____

Step 6.3：停止条件を読む

回数上限 [budget] はツールを実行する前に確認します。ただし、そのツールを要求したモデル呼び出しは、すでに課金対象になっている場合があります。tool_budget_exhausted、round_budget_exhausted、tool_rejected、output_rejected は診断用の状態であり、回答成功ではありません。履歴の所要時間はローカルのツール実行時間で、モデルの遅延 [latency] は含みません。APIの時間は別のログに記録します。

変更して再実行：AGENT_QUESTION の LabA を LabB に置き換え、エージェントのセルを再実行します。get_slots の引数が新しい部屋になり、その火曜日の1時間枠に基づいて答えていますか。出力が置き換わる前に両方の履歴を保存してください。追加のモデル呼び出しが発生します。Lab 6の考察には両方の部屋の結果を残します。

Step 6.4：APIを使わず実行境界をテストする

次のセルは、未定義の delete_booking と、空き状況データにないFridayの要求を拒否します。続いて、モデルの代わりに決まった応答を返すテスト用コード [test double] が、実行予算0の状態です。tool_budget_exhausted、空の履歴、api_log が増えていないことを確認してください。

この決定的テスト [deterministic test] が示すのはアプリケーションの動作です。実際のエージェントが常に適切なツールを選ぶことまでは示しません。最終回答の規程と空き枠も確認します。許可された出典の参照だけでは、主張の裏付けになりません。

確認ポイント：実測した呼び出し履歴、名前・引数の拒否2件、予算0のテストがそろっていること。後で reflections['lab6'] に残る制約と次のテストを記入します。

60–65分は休憩です。 ノートブックと出力を保存し、管理ファイルが実行環境の外にも保存されていることを確認します。

Lab 7・画像を検索し、画素から答える

65–85分・原教材第8章・説明4分、実験12分、確認4分

概念：テキスト検索で画像の根拠を選ぶ

今回は説明文を索引に使うマルチモーダルRAG [caption-indexed multimodal RAG] です。短い説明文を埋め込み、画像を順位付けし、選んだ画像を視覚入力に対応するモデルへ渡します。画像とテキストに共通の埋め込み空間を使う方式ではありません。説明文は主題を示しますが棒の数値を含めないため、画像の選択と数値の読み取りを分けて確認できます。

Step 7.1：検証済み画像を読み込む

次のセルは、授業用リポジトリから2枚のPNGグラフを取得し、リリース時のSHA-256ハッシュ [hash] と照合します。ハッシュはファイルの同一性を確認するもので、グラフの主張が正しいことを保証しません。

IMAGE_RECORDS は固定の画像ID、説明文、ファイル名を関連付けます。ローカル実行では SESSION2_DATA_DIR にダウンロードした data フォルダを指定できます。

画素を見る前に、両方の説明文を読んでください。説明文だけで火曜日の利用席数が分かりますか。 _____

Step 7.2：どの画像が最上位になるか予想する

image_search は埋め込みを正規化し、内積 [dot product] で順位を付けます。How many occupied seats were recorded on Tuesday?、つまり「火曜日の利用席数はいくつか」に最適な画像を予想してから比較セルを1回実行します。両条件で質問と選択画像は同じです。2回目だけ、PNGをbase64データURLとして detail='high' で追加します。

Step 7.3：説明文だけの回答と画像付き回答を比べる

表示されたグラフが根拠です。モデルの答えと照合する前に、自分で火曜日の棒のラベルを読んでください。別のグラフが取得された場合は、先に検索の失敗を診断します。視覚入力を足せば、資料選択の誤りまで直るとは考えないでください。

条件	選択した出典	実際の回答・回答保留 [abstention]	資料に裏付けられているか
説明文のみ	_____	_____	_____
説明文+画素	_____	_____	_____

Step 7.4：画像特有の制約を記録する

変更して再実行：席数の比較を保存し、IMAGE_QUESTION を How many completed print jobs were recorded on Tuesday?（火曜日の完了印刷件数はいくつか）に変更します。再実行してIMG-PRINTSへ切り替わるか確認し、火曜日の値を自分で読んでください。両方の質問・出典の比較を記録欄と考察に残します。レポートには最新結果だけが保存され、追加の生成リクエストは課金対象です。

実際の数値、単位、出典ID、根拠のない補足を記録します。IMG-SEATS という正しいIDがあっても、正しい棒を読んだとは限りません。小さい文字、曖昧な軸、ページの回転、低解像度、画像中の悪意ある指示は、別のテストが必要です。本演習は画像の検索と読解を扱います。音声、表、PDFのレイアウト抽出は、より長い演習で取り上げます。

確認ポイント：両画像の順位、2つの回答、人が読んだ数値がそろっていること。後で reflections['lab7'] に比較結果と新しい画像テストを書きます。

Lab 8・知識グラフとハイブリッド検索

85–110分・原教材第9章・説明5分、実験15分、確認5分

概念：類似性と関係条件を分ける

知識グラフ [knowledge graph] は、エンティティ [entity] と、方向・種類のある関係 [relationship] を表します。ここではチームが資格を **HAS_CERT** し、その資格が機器利用を **QUALIFIES_FOR** します。各辺 [edge] にID、状態、検証済みフラグを持たせます。チームから機器までは2ホップ [two-hop] の経路です。機器の説明が質問と似ていても、利用資格を与えることにはなりません。

このグラフはPython辞書で表した、授業用に整備済みのデータです。明示的な経路探索 [traversal] とベクトル候補を組み合わせたグラフ拡張RAGであり、Microsoft GraphRAGのコミュニティ要約、オントロジー推論器 [ontology reasoner]、本番の認可システムではありません。検証済みフラグは演習の前提です。本番では実際の根拠に基づく取り込み処理 [ingestion] が必要です。

Step 8.1：経路を手でたどる

E01～E05を読み、テキストセルに `Team Orion → certificate → device` を描き、関係の種類と辺IDを書きます。取り消された辺と、現行でも未検証の辺はどれでしょうか。どちらも除く理由を説明してください。

`eligible_paths` は現行かつ検証済みの辺を選び、**HAS_CERT**、次に **QUALIFIES_FOR** の順だけをたどります。方向と関係の種類が重要です。1ホップでは資格までしか届かず、利用可能機器は返しません。2ホップで必要な関係を満たせます。今回の制限付き探索では、モデルが生成した任意のデータベースクエリを実行しません。

Step 8.2：1ホップ、2ホップ、ベクトル候補を比較する

次のセルを実行します。`graph_candidates` は両機器の説明をテキスト類似度で順位付けし、`hybrid` はそのリストからグラフ上の利用条件に合うものを残します。今回は小さな候補集合の全件を順位付けします。大規模検索で先に候補を切り詰めた場合、グラフ条件だけでは最初から候補に入らなかった機器を取り戻せません。

比較項目	観察結果
1ホップで利用可能と判定された機器	_____
2ホップの辺IDと到達機器	_____
ベクトル候補の順序	_____
グラフ条件適用後に残ったID	_____
回答と出典	_____

Step 8.3：生成された説明を検証する

生成モデルには、選んだ辺の記述、現行P03、利用条件に合う機器本文を渡します。正しい機器名を挙げるだけでなく、チーム・資格・機器をつなぐ説明になっているか確認してください。`check_answer` は許可した出典IDを調べますが、回答文が経路の根拠を十分に説明したかは調べません。実際の回答を2本の辺とP03に照らして評価します。

Step 8.4 : 関係を取り消して再評価する

次のセルはグラフをディープコピー [deep copy] し、元データを変えずにE01を取り消します。ローカル探索の利用可能機器は空になり、未知のチームも結果なしになることを確認します。その後、**空の根拠資料**を別の課金対象リクエストで送り、回答保留を観察します。コードで確定するグラフの結果と、モデルの実際の振る舞いは区別してください。

変更して再実行：確認セルの `revoked[0]['status'] = 'revoked'` を `revoked[0]['verified'] = False` に置き換えます。ディープコピーは残し、再実行してください。今度のE01は現行ですが未検証です。それでも経路なしが正しい理由を説明します。根拠なしの生成も再実行されます。取消と未検証を分けて記録してください。

記録：取消後 _____ 未知チーム _____ 根拠なしの回答 _____

確認ポイント：どの関係が結果を変えるかを示し、現行と検証済みの違い、グラフも不完全・不正確になり得る理由を説明できること。後で `reflections['lab8']` に辺IDと未使用のテスト [held-out test] を書きます。例えば、独立した有効資格を2つ持つチームを試せます。

確認と提出・110–120分

Step 9.1 : 記録を仕上げる

次のセルの `reflections` 4項目と `human_review` 4項目を、表と実際の出力を使って埋めます。例文や空欄を残さないでください。実行すると文字列をメモリに反映し、APIは呼びません。空のまま再実行すると、前の内容が消えます。

各演習は**実測記録1点、記録に基づく説明1点**で、合計8点です。適切に診断した失敗も評価対象です。モデルが成功しただけでは考察にはなりません。「どの層で失敗したか、または何が未確認か」「根拠は何か」「変更を1つ試すなら、どの新しいテストで評価するか」を1分で説明できるようにします。

Step 9.2 : 今回作成したリソースを削除する

退出前に削除セルを実行します。ローカル管理ファイルに記録したIDだけを対象とし、ベクトルストア、続いて元ファイルを削除します。成功するたびに記録を更新し、404は削除済みとして扱うため、中断後も再実行できます。プロジェクト内の全リソースを列挙して削除する処理ではありません。

`complete: True` を確認します。失敗した場合は管理ファイルを保持し、該当エラーを解決してから再実行します。未削除のリソースがあれば、更新された管理ファイルをダウンロードしてください。ストアの期限切れだけでは元のFilesは削除されません。削除後にLab 5を再利用する場合は、作成セルから実行し直します。他の実験記録は残り、提出に使えます。

Step 9.3 : 出力して提出する

出力セルを実行し、`reflections complete: True` と `cleanup complete: True` の両方を確認します。前者は空欄がないかを調べるだけで、回答品質の判定ではありません。`rag_session2_report.json` と保存済み `.ipynb` を提出します。テキストセルの記録はノートブックにしか残りません。レポートには指定した観察と使用量が入り、キー、全グローバル変数、base64画像データは含まれません。

復旧とトラブルシューティング

問題	対応
索引作成が未完了	同じ管理ファイルで再実行。2回試したらペアで確認して次へ進む
Files・Vector Storesの権限がない	講師と権限を確認。Lab 5は共同結果を使い、POLICIESを定義して後の演習を進める
実行環境が失われた	保存済み session2_resources.json を設定前にColab Filesへ戻し、必要な定義を再実行する
作成中にタイムアウト	プロジェクト画面で rag2-classroom-<run_id>/rag2-<run_id>_ の名前を確認し、今回のリソースだけを管理ファイルと照合してから再試行する
削除エラー	原因を解決し同じ管理ファイルで再実行。必要なら、今回のものと確認できたIDだけを手動削除する
画像のハッシュ不一致・取得失敗	リリース済み画像と通信を確認、またはローカルフォルダーを指定。問題を隠すために検証を無効にしない
出力拒否	状態と許可出典を確認。裏付けのある回答とブロックを別に記録する
エージェントの上限到達	履歴を分析し、成功させるためだけに上限を増やさない

マネージド検索が使えない場合は、新しい実行環境で設定を実行し、プラットフォームのセルから POLICIES の代入文だけを新規コードセルへコピーして実行すれば、Lab 6～8を進められます。Lab 5は共同実行・記録済み結果・未完了のいずれかを明記し、未実施を完了としないでください。

発展学習と参考資料

原教材第5章でVectara、第7章でエージェントフレームワークとMCP、第8章で表・音声・クロスモーダル埋め込み [cross-modal embedding]、第9章でNeo4j・Cypher・GraphRAGを学べます。本授業の簡略化した構成だけでは、本番認可、包括的な攻撃耐性、大規模時の性能は確認できません。

[Python解説](#)と[公式参考資料](#)も参照してください。コードと入力は英語版と共通です。