

第2次课 · RAG平台、AI智能体、多模态 RAG与知识图谱

简体中文 · 学员实操手册

作者 [Author]

Rajkumar Rajagobalan

请配合可执行的Colab笔记本使用本手册，通过正文开头的链接打开。观察结果可记录在纸上或自己保存的笔记本中。

2小时 · 实验5–8 · 适合具有中高级Python经验的学员 · Google Colab + OpenAI

姓名 / 小组编号：_____ 日期：_____

[在Colab中打开简体中文版](#)

本次课程为一所**虚构大学的创客空间**搭建助手。规定、房间时段、图表、人物组织及关系数据均为专门编写的教学数据。课程延续第1次课的证据 [evidence] 与安全护栏 [guardrail] 概念，但使用新的笔记本和运行时，不依赖上次的变量。

对应原教材第5、7、8、9章，在本系列中依次编号为**实验5、6、7、8**。平台实验将Vectara章节中的生命周期管理思路应用到OpenAI托管检索 [managed retrieval]。图谱使用内存中的小型数据结构，不安装Neo4j或Microsoft GraphRAG。

语言说明：技术术语附英文，方便与代码对应。代码、注释、变量名、模型名、测试问题和数据正文保持英文，以保证各版本的实验条件一致。请勿用中文释义替换代码中的问题；观察和反思可以用中文填写。

课程安排与实验记录

课堂时间	活动	需要保存的记录
00–10	环境配置与预检	READY、模型名称、资源记录保存方案
10–35	实验5：RAG平台	索引就绪、筛选结果、带来源的回答
35–60	实验6：AI智能体	实际工具调用轨迹与边界测试
60–65	休息	已保存的笔记本和资源记录文件
65–85	实验7：多模态RAG	检索到的图片、仅描述 / 附图片的对比
85–110	实验8：知识图谱	两跳证据、混合检索候选、撤销关系测试
110–120	审查、清理与提交	笔记本、JSON报告、清理完成记录

每个实验按**预测→运行→检查→解释**展开。直接编辑Colab文本单元格 [text cell] 中的表格，或新增Text单元格记录实测结果。最后的反思代码会导出字符串，而文本单元格中的记录只保存在笔记本中。不要把预期答案当作实测结果；有依据的问题诊断同样有价值。

环境配置 · 00–10分钟

步骤0.1 — 保存副本并配置环境

- 在Colab中选择 **Copy to Drive**，将副本命名为 RAG_Session2_<name-or-pair>。
- 使用Python 3和CPU，无需GPU、数据库服务器或额外服务账号。

3. 在 **Secrets** 中添加 `OPENAI_API_KEY`，启用笔记本访问权限。项目需允许使用指定模型以及 Files / Vector Stores。
4. 阅读下方配置代码，运行一次，确认 **READY** 和预检回答。API用量计入自己的OpenAI项目。

步骤0.2 — 理解哪些状态会保留

`api` 是基于Python标准库的HTTP客户端 [HTTP client]。它只允许访问固定OpenAI地址下的课堂端点 [endpoint]，发送前记录请求尝试，并统计成功和失败请求的耗时，不记录授权标头。超时 [timeout] 为45秒，当前内存状态下最多尝试100次普通请求。达到上限后仍允许DELETE，避免无法清理资源。代码不自动重试 [automatic retry]。

`embed` 批量发送未处理的字符串，将返回行恢复为输入顺序，检查1,536维并归一化 [normalization]。缓存 [cache] 使用 (`model`, `exact_text`) 作为键，避免混用不同模型或不同文本的结果。`grounded` 发送问题、带ID的证据，并可附加图片像素。它要求输出 `answer`、`abstain`、`sources`。`check_answer` 检查字段类型和来源白名单 [allowlist]，但不验证语义蕴含 [entailment]，即证据是否真正支持回答主张，因此仍需人工审查。

`session2_resources.json` 是资源记录文件 [resource ledger]，只保存本次运行ID、向量存储ID和文件ID。每次成功创建后立即更新，以便中断后复用已记录的资源。同一运行时 [runtime] 中重跑配置会保留计数；重置运行时丢失内存计数。本地文件可能在内核重启后保留，但虚拟机 [VM] 被销毁时也会丢失，请在实验5下载。密钥不得写入该文件、代码、截图或提交材料。

向量存储设置为最后使用后一天过期 [expiry]，但原始上传的Files对象需要单独删除。课堂请求次数限制不等于账号消费上限。`store=False` 控制Responses的响应存储，不代表关闭账号范围内的所有数据保留。

步骤0.3 — 处理配置失败

401检查密钥；403 / 404检查项目、模型与Files权限；429检查额度和速率限制 [rate limit]。第二次配置仍失败时，与环境正常的同学结对，并明确标注共同运行或引用的记录。创建资源时若超时，不能盲目重跑，因为服务端可能已创建成功；请参考末尾恢复步骤。实验6–8需要配置和 `POLICIES` 定义，但不会调用实验5的托管搜索。

记录：READY _____ 模型 _____ 资源记录文件保存位置 _____

`grounded` 通过 `guardrail_status` 区分 `contract_passed`、`abstained`、`output_rejected`、`api_refusal` 和 `incomplete`。被拒绝的结构化输出保留在 `raw_output` 中供诊断，不能视为已接受的回答。例如，拒答时仍附带来源会被拒绝。网络和HTTP故障仍会显式报错。READY表示API调用已完成，还应检查预检响应的状态。

实验5 · 托管RAG平台

10–35分钟 · 原教材第5章 · 讲解5分钟、实验15分钟、审查5分钟

概念：平台承担哪些工作

托管检索服务处理上传文本的解析 [parsing]、切分 [chunking]、嵌入 [embedding] 和索引搜索。应用仍负责来源质量、可用性规则、回答指令、评估、权限与资源生命周期。本例使用托管检索后端，再显式调用生成接口，并不声称与Vectara完整平台或其幻觉修正API功能相同。

步骤5.1 — 检查四条规定

找到现行P01与历史P02：前者规定每天最多两小时，后者曾允许四小时。P03规定设备使用资格，P04说明支持渠道。预测包含“four hours”的问题可能优先检索到哪条资料。

步骤5.2 — 上传、关联并等待索引就绪

运行下方单元格。upload_policy 构造多部分表单 [multipart form]，文件名加上唯一运行ID前缀。Files对象保存原始字节；将其关联到向量存储 [vector store] 后开始索引，并设置 source_id 和 status 属性。

prepare_platform 在创建前检查资源记录。轮询 [polling] 最多读取12次 file_counts，每次未就绪时等待三秒，网络耗时另计。若返回 indexing_pending，保留记录文件并重跑该单元格。两次尝试后仍未就绪，就使用同伴的平台输出继续，避免耗尽课堂时间。若索引出现 failed，先排查，不要在不完整语料上查询。

按提示下载 session2_resources.json，保留到清理完成。存储对象存在，不代表所有文件都已可检索。

记录：完成文件数 _____ 状态 _____ 是否下载记录文件 _____

步骤5.3 — 比较筛选前后的结果

阅读 platform_search。它向服务请求最多四条结果，可按文件属性筛选 [attribute filtering]，并保留来源ID、状态、分数和返回段落。这里返回的是平台生成的文本块；与第1次课按文档去重的评估不同，此函数不保证k个不重复文档。

运行下一单元格。它针对 Can a student book a makerspace room for four hours per day?，即“学生每天能否预约创客空间四小时”，分别执行不筛选与仅现行来源的搜索，再使用筛选后的证据生成回答。

检查项	观察结果
不筛选时的ID / 状态	_____
筛选后的ID / 状态	_____
筛选后是否排除了P02?	_____
生成回答及引用ID	_____
回答是否符合现行P01?	_____

步骤5.4 — 解释结果

修改后重跑：先保存四小时问题的结果，将 PLATFORM_QUESTION 改为 What qualification does a team need to use equipment?（团队使用设备需要什么资格），再运行检索 / 生成单元格。检查P03是否支持新回答。在文本记录和最终反思中保留两个问题及其引用ID；observations['lab5'] 只保留最近一次运行，重跑会增加API请求。

分别指出一项交给平台的工作和一项仍由应用承担的责任。检索分数不是事实正确率。本例的属性由可信教学代码设置，但该筛选器不是多租户授权 [authorization] 系统。来源ID有效，也不能证明回答中的时长正确。

检查点：四个文件就绪；筛选列表没有历史来源；回答已与P01核对。如果未筛选时也没有P02，请如实记录，不要虚构排名。

稍后在 `reflections['lab5']` 中记录ID、实际回答的时长和责任分工。

实验6 · 有明确执行边界的AI智能体

35–60分钟 · 原教材第7章 · 讲解5分钟、实验15分钟、审查5分钟

概念：模型提出调用，应用执行操作

智能体循环 [agent loop] 先发送问题和工具定义，验证模型请求的函数调用 [function call]，执行获准函数，再用对应的 `call_id` 返回结果，让模型继续。函数调用是请求应用采取行动，不是可以交给 `eval` 执行的Python代码。

步骤6.1 — 阅读两个只读工具

`search_policy` 对现行规定执行简单的本地词法检索 [lexical retrieval]，按词语重叠排序，不调用实验5的平台。`get_slots` 读取固定的星期二空闲时段快照 [snapshot]，不会预约房间。`dispatch` 独立于模型的严格模式 [strict schema]，再次检查工具名、参数键和允许值，这一检查保护实际执行边界。

`run_agent` 最多执行三次工具、进行四轮模型请求。`parallel_tool_calls=False` 便于观察调用轨迹，但Python循环仍会处理每一个返回调用。工具结果保留原始 `call_id` 加入会话历史。最终回答只允许引用工具实际返回的证据ID。

步骤6.2 — 预测并运行真实循环

AGENT_QUESTION 询问预约时长上限，以及LabA在星期二哪些空闲时段符合规定。先预测工具和顺序，再运行单元格。检查 `status`、最终回答及每条轨迹中的参数和来源ID。记录实际发生的调用，模型可能选择不同顺序，也可能触及限制。

项目	观察结果
预测的工具顺序	_____
实际工具与参数	_____
最终状态 / 引用来源	_____
规定时长与合规的星期二时段	_____
是否错误地声称已完成预约？	_____

步骤6.3 — 检查停止条件

调用预算 [budget] 在工具执行之前检查，但请求该工具的模型调用可能已经产生费用。`tool_budget_exhausted`、`round_budget_exhausted`、`tool_rejected`、`output_rejected` 都是诊断状态，不是成功回答。轨迹中的耗时只测量本地工具执行，不含模型延迟 [latency]；API日志单独记录请求耗时。

修改后重跑：将 AGENT_QUESTION 中的 LabA 换成 LabB，再运行智能体单元格。检查 `get_slots` 是否收到新房间参数，回答是否使用该房间星期二的一小时时段。输出覆盖前保存两份轨迹。此操作会新增真实模型调用，请在实验6反思中记录两个房间的结果。

步骤6.4 — 不调用API，测试执行边界

运行下一单元格。它拒绝未知的 `delete_booking` 工具，以及快照不支持的Friday请求。然后用脚本测试替身 **[test double]**，而非真实模型，在工具预算为零时提出调用。确认返回 `tool_budget_exhausted`，轨迹为空，且 `api_log` 未增加。

这些确定性测试 [deterministic test] 证明的是应用控制逻辑，不证明真实智能体总能选对工具。最终回答仍需核对规定和时段；允许引用某个来源，不等于来源支持全部主张。

检查点：保存真实调用轨迹、两项本地名称 / 参数拒绝结果，以及零预算测试。稍后在 `reflections['lab6']` 中说明剩余风险与下一项测试。

60–65分钟休息。 保存笔记本及输出，并确认资源记录文件已保存在运行时之外。

实验7 · 检索图片，再依据像素回答

65–85分钟 · 原教材第8章 · 讲解4分钟、实验12分钟、审查4分钟

概念：用文本检索选择视觉证据

本例是以图片描述建立索引的多模态RAG [caption-indexed multimodal RAG]：对短描述生成嵌入，按相关性选择图片，再交给支持视觉输入的模型。它不是图文共享嵌入模型。描述只说明主题，不包含柱状图数值，因此图片选择与数值读取是两个可分别观察的任务。

步骤7.1 — 加载并验证图片

运行图片加载单元格。它从课程仓库下载两张原创PNG图表，并与发布清单中的SHA-256哈希 [hash] 核对。哈希验证文件完整性，不验证图表陈述是否真实。IMAGE_RECORDS 将稳定图片ID、描述和文件名关联起来。本地运行时可用 `SESSION2_DATA_DIR` 指向下载好的 `data` 文件夹。

看图片前先读两条描述。任何一条是否直接给出了星期二的占用座位数？_____

步骤7.2 — 预测哪张图片排第一

`image_search` 归一化嵌入向量后，通过点积 [dot product] 排序。先预测 `How many occupied seats were recorded on Tuesday?`，即“星期二记录了多少个被占用的座位”，应选哪张图片，再运行比较单元格一次。两次请求使用同一问题和所选来源，第二次额外将PNG以base64数据URL传入，并设置 `detail='high'`。

步骤7.3 — 比较仅描述与附图片的回答

显示的图表就是证据。先自己阅读星期二柱子的数值标签，再核对模型回答。如果检索错了图，应先诊断检索问题；加入视觉输入不能自动纠正来源选择错误。

条件	所选来源	实际回答 / 证据不足时拒答 [abstention]	证据是否支持？
仅描述	_____	_____	_____
描述 + 像素	_____	_____	_____

步骤7.4 — 记录视觉输入特有的风险

修改后重跑：先保存座位数比较，将 `IMAGE_QUESTION` 改为 `How many completed print jobs were recorded on Tuesday?`（星期二完成了多少项打印任务），再运行。检查检索器是否切换到-PRINTS，并亲自读取星期二数值。在记录和最终反思中保存两组问题 / 来源对比；否则报告只保留最新结果。新的生成请求会计费。

记录实际数值、单位、来源ID和无依据的补充。合法的 `IMG-SEATS` ID不代表模型读对了柱子。小字、含糊的坐标轴、页面旋转、低分辨率，以及图片中的恶意指令，都需要独立测试。本实验覆盖图片检索与视觉读取；音频、表格和PDF版面解析适合更长的课程。

检查点：两张图片的排名、两次响应、人工读出的数值均有记录。稍后将比较结果和一项新的视觉测试写入 `reflections['lab7']`。

实验8 · 知识图谱与混合检索

85–110分钟 · 原教材第9章 · 讲解5分钟、实验15分钟、审查5分钟

概念：相似度和关系约束解决不同问题

知识图谱 [knowledge graph] 描述实体 [entity] 及有方向、有类型的关系 [relationship]。本例中，团队 `HAS_CERT` 某项证书，而证书 `QUALIFIES_FOR` 某台设备。每条边 [edge] 都有ID、状态和已验证标记。团队到设备需要两跳 [two-hop] 路径。设备描述与问题相似，并不能授予使用权限。

图谱是用Python字典表示的人工整理教学数据。本例通过显式遍历 [traversal] 与向量候选实现图谱增强RAG，不是Microsoft GraphRAG社区摘要、本体推理器 [ontology reasoner]，也不是已部署的授权系统。可信标记是课堂假设；生产数据接入 [ingestion] 必须根据真实证据建立它。

步骤8.1 — 手动跟踪路径

阅读E01–E05，在文本单元格画出 `Team Orion → certificate → device`，标注关系类型和边ID。哪条边已撤销？哪条边虽为现行状态，却未经验证？为什么两者都必须排除？

`eligible_paths` 先保留现行且已验证的边，再只按 `HAS_CERT`、`QUALIFIES_FOR` 的顺序遍历。方向和类型都影响结果。一跳只能到证书，因此不会返回可用设备；两跳才可能完成要求的模式。这种有界遍历不执行模型自由生成的数据库查询。

步骤8.2 — 比较一跳、两跳与向量候选

运行下一单元格。`graph_candidates` 按文本相似度为两个设备描述排序，`hybrid` 将有序候选与图谱允许的设备取交集。本例对小型候选集完整排序。如果大规模检索先截断候选，图谱约束无法找回从未进入候选集的相关设备。

比较项	观察结果
一跳返回的可用设备	_____
两跳路径的边ID和最终设备	_____
向量候选顺序	_____

比较项	观察结果
图谱约束后保留的ID	_____
生成回答及来源	_____

步骤8.3 — 审查生成的解释

生成器收到所选边的陈述、现行P03以及符合条件的设备文本。检查回答是否解释了团队、证书和设备之间的关系，而非只报出正确设备名。`check_answer` 只验证允许的来源ID，不验证回答是否完整解释了路径。应把实际回答与两条边及P03逐一核对。

步骤8.4 — 撤销关系后重新测试

下一单元格先深复制 [deep copy] 图谱，再撤销E01，不修改基线数据。此时本地遍历应返回零个可用设备，未知团队也应返回空结果。随后另发一次付费生成请求，提供空证据以观察是否拒答。确定性的图谱结果与模型的实际表现要分开记录。

修改后重跑：将控制单元格中的 `revoked[0]['status'] = 'revoked'` 替换为 `revoked[0]['verified'] = False`，保留深复制，再运行。此时E01仍为现行状态，但未经验证，请解释为什么仍应返回空路径。空证据生成请求也会再次执行。分别记录“已撤销”和“未经验证”两种情况。

记录：撤销后结果 _____ 未知团队结果 _____ 空证据回答 _____

检查点：能够指出改变结果的具体关系，区分“现行”和“已验证”，并说明图谱仍可能不完整或错误。稍后在 `reflections['lab8']` 中记录边ID及一个未参与调优的测试 [held-out test]，例如拥有两项独立有效证书的团队。

审查与提交 · 110–120分钟

步骤9.1 — 完成证据记录

根据表格和实际输出，填写下一单元格全部四项 `reflections` 和四项 `human_review`，不要保留占位句。运行后将字符串写入内存，不调用API。若保留空字符串重新运行，会清空之前的值。

每个实验实测记录1分，基于记录的解释1分，共8分。准确诊断的失败可以得分，模型回答成功本身不能代替分析。准备一分钟汇报：哪一层失败或仍不确定，有什么证据，以及用什么新测试检验一项拟议修改。

步骤9.2 — 删除本次课程创建的资源

离开前运行清理单元格。它只删除本地记录文件中的ID：先删除向量存储，再删除原始上传文件。每次成功后更新记录，将404视为资源已不存在，因此中断后可以重跑。它不会列出并批量删除项目中的所有资源。

确认 `complete: True`。若清理失败，保留记录文件，解决具体错误后重试；仍有剩余资源时，下载更新后的记录。不要把向量存储过期等同于Files对象删除。清理成功后如需重做实验5，应重新运行创建单元格，其他实验记录仍可导出。

步骤9.3 — 导出并提交

运行导出单元格，确认 `reflections complete: True` 与 `cleanup complete: True`。前者只检查字段非空，不评判答案质量。提交 `rag_session2_report.json` 和保存的 `.ipynb`；文本单元格记录仅保存在笔记本中。报告包含指定观察与用量，不包含密钥、全部全局变量或base64图片载荷。

恢复与常见问题

问题	处理方法
平台仍在索引	保留同一记录文件重跑；两次后结对继续
无Files / Vector Stores权限	与教师核对项目权限；实验5使用共同结果，定义 <code>POLICIES</code> 后继续其他实验
运行时丢失	配置前先将保存的 <code>session2_resources.json</code> 上传回 Colab Files，再重跑必要定义
创建资源时超时	在项目控制台按 <code>rag2-classroom-<run_id> / rag2-<run_id></code> 前缀查找，仅核对本次资源，再更新记录并决定是否重试
清理错误	排查后用同一记录重跑；必要时仅手动删除已确认属于本次实验的ID
图片哈希不符 / 下载失败	检查发布文件和网络，或指定本地目录；不要关闭验证来掩盖问题
输出被拒绝	检查响应状态和允许来源，将拦截与有依据的回答分别记录
智能体耗尽预算	阅读轨迹，不要仅为得到成功结果而提高上限

托管索引不可用时，可在新运行时完成配置，再将平台单元格中的 `POLICIES` 赋值语句单独复制到新代码单元格运行，然后继续实验6–8。实验5应标为共同运行、引用记录或未完成，不能把未运行的实验报告为完成。

延伸学习与参考资料

原教材第5章扩展Vectara，第7章介绍智能体框架和MCP，第8章涉及表格、音频与跨模态嵌入 [cross-modal embedding]，第9章介绍Neo4j、Cypher和GraphRAG。课堂简化实现不能证明生产授权、全面攻击防护或大规模性能。

另见[Python代码说明](#)和[官方参考资料](#)。代码标识与测试输入在各语言版本中保持一致。